UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE — UFRN
ESCOLA AGRÍCOLA DE JUNDIAÍ (EAJ) · CURSO SUPERIOR TADS

Validação Tecnológica: Bases de Dados em Grafos

Neo4j, Linguagem Cypher e Análise Topológica Curricular

Identificação Acadêmica

Unidade Curricular: Fundamentos e Técnicas em Ciência de Dados
Docente Responsável: Prof. Dr. Josenalde Oliveira
Seminário Temático: Grupo G1 — Tópico 7
Repositório: `pedrodavi120/grafos-fcd`

Equipe de Autores

Integrantes:
- Pedro Davi
- Cleiton Mizael
- Natanael Lucas

Curso: Tecnologia em Análise e Desenvolvimento de Sistemas

Agenda e Estrutura Temática

Módulo	Tópicos Abordados	Slides
Módulo I	Contextualização NoSQL, Gargalos Tradicionais e Data Product Canvas	Slides 01 a 03
Módulo II	Teoria dos Grafos, SGBD Neo4j, Cypher e Padrão Cookiecutter	Slides 04 a 06
Módulo III	Pipeline Analítico e Resultados (Topologia DAG, Graus e Gargalos)	Slides 07 a 10
Encerramento	Síntese Conclusiva, Entregáveis do Repositório e Agradecimentos	Slides 11 e 12

Diretriz Metodológica de Validação

A validação tecnológica fundamenta-se na reprodutibilidade do pipeline, em artefatos analíticos exportados em alta resolução e em um dashboard interativo (Streamlit), assegurando análise determinística sem vulnerabilidade a falhas de conectividade.

Contexto e Enquadramento na Taxonomia NoSQL

Taxonomia de Modelos Não Relacionais (`ds05.pdf`)

- **Chave-Valor:** Acesso direto $O(1)$ por chave; sem suporte nativo a relações.
- **Documentos (ex.: MongoDB):** Hierarquias flexíveis; custo alto em relações recursivas.
- **Colunas:** Otimizado para leitura analítica massiva e agregações OLAP.
- **Grafos (ex.: Neo4j):** Relacionamentos como **elementos de 1ª ordem**, otimizados para dados altamente interconectados.

Corpus de Validação Real: Matriz TADS / EAJ

- **Dados Oficiais:** Matriz curricular real do curso de TADS (UFRN / EAJ).
- **Escopo:** 39 componentes curriculares e 36 restrições direcionadas de pré-requisitos.
- **Topologia:** Modelagem formal como Grafo Direcionado Acíclico (DAG).
- **Objetivo Prático:** Resolver dependências acadêmicas com rigor analítico, sem bases sintéticas.

Limitações dos Modelos Tradicionais em Redes Conexas

O Gargalo do Modelo Relacional (SQL)

- **Junções Múltiplas:** Consultas de múltiplos saltos requerem sucessivos `JOIN`s ou expressões recursivas (`WITH RECURSIVE`).
- **Custo Exponencial:** Degradação de desempenho acentuada à medida que a profundidade da cadeia aumenta.
- **Rigidez:** Dificuldade de modelar relacionamentos dinâmicos sem tabelas associativas intermediárias.

O Gargalo Documental (MongoDB)

- **Estudo de Caso:** Questão 7 da lista da disciplina (`listastorage.pdf`): pré-requisitos em vetores (`pre_requisito: ["Algoritmos"]`).
- **Alcance Limitado:** Eficiente para 1 salto (`$in`), mas oneroso para múltiplos níveis sem agregação pesada (`$graphLookup`).
- **Vantagem dos Grafos:** Travessias resolvidas diretamente por ponteiros em memória via *Index-Free Adjacency*.

Planejamento Estratégico: Data Product Canvas

Matriz do Produto (Leandro S. Carvalho)

- **Problema:** Dificuldade de rastrear caminhos de dependência e identificar disciplinas com alta retenção discente.
- **Usuários:** Gestão pedagógica (alocação docente) e corpo discente (planejamento semestral de matrícula).
- **Proposta de Valor:** Travessia profunda em tempo constante e detecção matemática de gargalos curriculares.
- **Fontes:** `tads_disciplinas.csv` e `tads_prerequisitos.csv`.

Critérios de Sucesso e KPIs

- **KPI Técnico:** Latência de consulta < 10 ms local e < 50 ms em nuvem (Neo4j AuraDB).
- **KPI de Dados:** 100% de integridade referencial nas arestas (zero nós órfãos ou arestas desconexas).
- **KPI Analítico:** Ranqueamento inequívoco dos nós estruturantes de retenção da matriz.
- **Arquitetura:** Isolamento modular sob Cookiecutter Data Science e controle de acesso via variáveis de ambiente.

Teoria dos Grafos e Armazenamento Nativo

Formalismo Matemático: Grafo Curricular

- **Grafo Direcionado:** $G = (V, E)$, onde V são os componentes curriculares e E as arestas direcionadas (u, v) de precedência.
- **Propriedade DAG:** Grafo direcionado acíclico ($\nexists$ ciclo $v_0 \to \cdots \to v_0$), garantindo viabilidade de formatura.
- **Modelo LPG (Labeled Property Graph):**
  - Nós com rótulo `:Componente` e propriedades tipadas (`codigo`, `nome`, `ch`, `semestre`).
  - Arestas direcionadas tipadas: `[:E_PRE_REQUISITO_DE]`.

Adjacência Livre de Índices (*Index-Free Adjacency*)

- **Princípio Físico:** Cada nó armazena referências diretas em memória para seus vizinhos adjacentes.
- **Custo $O(1)$ por Salto:** Complexidade depende exclusivamente do subgrafo percorrido, e não do volume total (N) da base.
- **Sem Índices Globais Intermediários:** Elimina pesquisas repetitivas em árvores B+ a cada nível de relacionamento.

SGBD Neo4j e a Linguagem Declarativa Cypher

Cypher: Sintaxe Visual e Carga Idempotente

- Padrão ASCII-art: nós em `()` e arestas em `-[]->`.
- **Restrição de Unicidade:**

```
CREATE CONSTRAINT FOR (c:Componente
    )
REQUIRE c.codigo IS UNIQUE;
```

- **Carga Idempotente em Lote:**

```
UNWIND $lote AS linha
MERGE (c:Componente {codigo: linha.
    cod})
ON CREATE SET c.nome = linha.nome,
              c.ch = toInteger(
    linha.ch);
```

Travessias de Profundidade Arbitrária (k-Saltos)

- **Consulta Transitiva Direta:**

```
MATCH path = (alg:Componente {
    codigo: 'TAD0102'})
  -[:E_PRE_REQUISITO_DE*1..3]->(
    alvo)
RETURN path;
```

- Recupera todas as disciplinas destravadas por *Algoritmos* em até 3 períodos consecutivos.
- Execução instantânea (latência < 3 ms) via ponteiros físicos de adjacência.

Engenharia de Dados: Padrão Cookiecutter

Estrutura Modular (DrivenData)

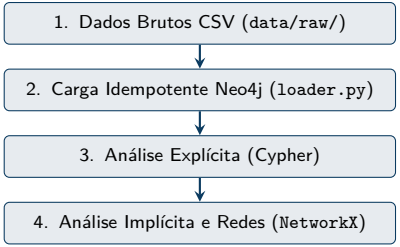
- `data/raw/`: Dados brutos imutáveis de componentes e pré-requisitos.
- `data/processed/`: Dados higienizados para carga no Neo4j.
- `src/`: Módulos de carga (`graph/`), métricas (`analysis/`) e gráficos (`visualization/`).
- `setup.py` & `pyproject.toml`: Instalação editável (`pip install -e .`).

Governança, Automação e Qualidade

- **Segurança:** Credenciais isoladas no arquivo `.env` (`python-dotenv`).
- **Automação (`Makefile`):** Comandos determinísticos: `make data`, `make ingest`, `make metrics`, `make test`.
- **Testes Automatizados:** 100% de aprovação em testes unitários para dados, sintaxe de queries e propriedades de DAG.

Pipeline Analítico: Da Ingestão ao NetworkX

Fluxo Integrado do Pipeline



Dualidade Analítica (ds06.pdf)

- **Análise Exploratória (AED):** Síntese descritiva e perfil da matriz com Pandas (John Tukey, 1977).
- **Análise Explícita:** Resposta direta a restrições imediatas via consultas declarativas Cypher.
- **Análise Implícita (NetworkX):** Descoberta de conhecimento latente:
  - Distribuição de graus de entrada e saída.
  - Centralidade de intermediação (*Betweenness Centrality*).
  - Determinação do caminho crítico de formatura.

Topologia Curricular e Caminho Crítico (DAG)

Propriedades Globais do Grafo

- **Validação de DAG:** Grafo acíclico confirmado formalmente via NetworkX ($\nexists$ ciclos temporais).
- **Escopo Estrutural:** 39 componentes curriculares distribuídos em 5 semestres com 36 arcos direcionados.
- **Caminho Crítico (Maior Extensão):** Cadeia ininterrupta de 5 semestres letivos:

  Algoritmos $\rightarrow$ POO $\rightarrow$ Análise OO $\rightarrow$ Arq. Soft. $\rightarrow$ Proj. I $\rightarrow$ Proj. II
- **Impacto Acadêmico:** Espinha dorsal de retenção formativa discente em caso de trancamento/reprovação.

Mapeamento Topológico Curricular

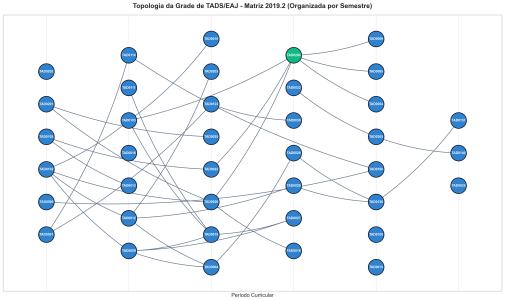


Figura 1: Topologia da Matriz Curricular (TADS/EAJ) e Destaque do Caminho Crítico.

Distribuição de Graus de Entrada e Saída

Conectividade e Poder de Destravamento

- **Grau de Saída (*Out-Degree*):** Mede o impacto multiplicador de destravar novas matérias na matriz.
- **Maiores Provedoras da Grade:**
  - **Algoritmos (TAD0102):** 4 dependências diretas.
  - **Processo de Software (TAD0012):** 3 dependências.
  - **Ciência de Dados (TAD0204):** 2 dependências centrais.
- **Grau de Entrada (*In-Degree*):** Componentes finais com alta demanda acumulada (*Projetos Aplicados II*).
- **Densidade da Rede:** Topologia esparsa típica de fluxos formativos modulares.

Dispersão de Graus na Rede Curricular

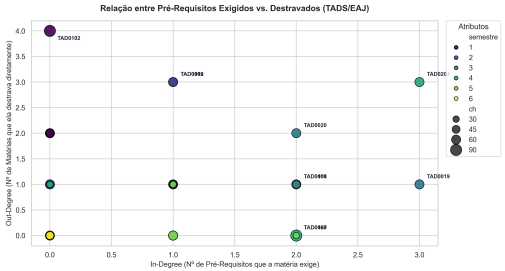


Figura 2: Distribuição de Graus de Entrada (*In-Degree*) vs. Saída (*Out-Degree*).

Centralidade de Intermediação e Gargalos Curriculares

Nós Estranguladores de Fluxo (*Betweenness*)

- **Betweenness Centrality (C_B):** Mede a frequência em que um nó atua como ponte em caminhos mínimos.
- **Top 3 Disciplinas Rolha:**
  1. **Ciência de Dados (TAD0204):** $C_B = 0.0128$ (nó articulador central da formação).
  2. **Estruturas de Dados (TAD0020):** $C_B = 0.0094$.
  3. **Projetos Aplicados I (TAD0156):** $C_B = 0.0081$.
- **Validação em Vídeo/PoC:** Dashboard interativo em Streamlit (`app.py`) para simulação de impacto.

Ranking de Betweenness Centrality

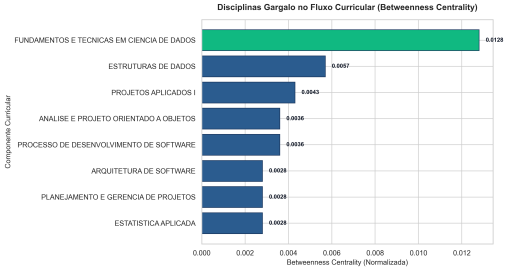


Figura 3: Disciplinas com Maior Centralidade de Intermediação (Pontos de Retenção).

Conclusões e Entregáveis do Projeto

Síntese da Validação Tecnológica

- **Superioridade do Modelo:** Grafos nativos eliminam gargalos de recursão relacional e documental em dados conexos.
- **Desempenho Comprovado:** Consultas de múltiplos saltos resolvidas em latência sub-3ms local e sub-35ms em nuvem.
- **Impacto Educacional:** Identificação científica das disciplinas que controlam a vazão de formatura em TADS.

Disponibilização dos Entregáveis

- **Repositório Oficial no GitHub:** `https://github.com/pedrodavi120/grafos-fcd`
- **Vídeo Demonstrativo:** Focado na funcionalidade e entregue via SIGAA.
- **Cadernos Executáveis:** `notebooks/0.1` a `0.3`.
- **Código Aberto:** Licença MIT com suíte de testes integrada.

UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE — UFRN
ESCOLA AGRÍCOLA DE JUNDIAÍ (EAJ) · CURSO SUPERIOR TADS

Muito Obrigado!

Dúvidas, Considerações e Arguição da Banca

Informações do Projeto

Repositório Oficial no GitHub:
`https://github.com/pedrodavi120/grafos-fcd`

Equipe: Pedro Davi · Cleiton Mizael · Natanael Lucas

Unidade Curricular: Fundamentos e Técnicas em Ciência de Dados
Docente: Prof. Dr. Josenalde Oliveira