Universidade Federal do Rio Grande do Norte
Análise e Desenvolvimento de Sistemas
Fundamentos e Técnicas em Ciência de Dados
Docente: Josenalde Oliveira

Exercícios de Fixação: armazenamento não relacional (NoSQL)

1. (Residência TI/Lais Edital 46/2019 – IMD/2019) Na última década houve o surgimento de novas soluções computacionais para armazenamento de dados diferentes da soluções relacionais clássicas. Estes novos bancos de dados ficaram conhecidos como bancos de dados NoSQL (Not-only SQL). Sobre este tema julgue as sentenças abaixo e assinale a alternativa correta.

I - O CouchDb é uma solução de armazenamento NoSQL baseada em documentos.
II - O Redis é uma solução de armazenamento NoSQL que organiza os dados em colunas.
III - O Neo4j é uma solução que utiliza teoria de grafos para o armazenamento dos dados.
IV - O Cassandra é uma solução de armazenamento baseada em chave-valor.

a) Apenas I e III
b) Apenas I, II e III
c) Apenas II e IV
d) Apenas III e IV

2. (Residência TI/Lais Edital 46/2019 – IMD/2019) Sobre o banco de dados mongoDB é INCORRETO afirmar que:

a) MongoDB é um banco de dados orientado a documentos com estrutura semelhante a objetos do tipo JSON.
b) As operações no MongoDB são feitas através da execução de funções.
c) No MongoDB, os schemas são dinâmicos, sendo possível em um mesmo documento ter dados com diferentes campos.
d) No MongoDB, pode ser utilizada a linguagem SQL para fazer consultas de dados.

3. (Residência TI/Lais Edital 46/2019 – IMD/2019) Você foi contratado para otimizar o desempenho de um sistema que estava apresentando constante lentidão. Após análise, foi constatado que o maior gargalo estava relacionado ao tempo prolongado de algumas consultas recorrentes ao banco de dados. Em seguida, foi decidido implantar um cache em memória para armazenar alguns dados comumente acessados. Por ser um sistema distribuído, este cache deveria estar acessível a qualquer módulo do sistema. Diante desse cenário, assinale a alternativa que indica a tecnologia mais indicada para auxiliar na implantação desse cache.

a) MongoDb
b) Redis
c) Firebase
d) HBase

4. A definição da primeira forma normal em bancos de dados relacionais estabelece que:

a) Os atributos normais, ou seja, os não chave, devem depender unicamente da chave primária da tabela.
b) Não deve haver relacionamentos do tipo muitos para muitos entre conjuntos de entidades.
c) Todos os atributos contém apenas um valor correspondente, singular e não existem grupos de atributos repetidos.
d) Todos os atributos devem ser funcionalmente independentes uns dos outros, ao mesmo tempo que devem ser dependentes exclusivamente da chave primária da tabela.

5. Os bancos de dados relacionais preocupam-se em garantir que suas transações possuam uma série de propriedades. Que propriedades são essas?

a) Atomicidade, concorrência, isolamento e particionamento.
b) Atomicidade, consistência, disponibilidade e durabilidade.
c) Atomicidade, concorrência, disponibilidade e particionamento.
d) Atomicidade, consistência, isolamento e durabilidade.

6. Considerando que o *shell* mongo é escrito em JS, execute o código abaixo no mongoDB considerando uma coleção chamada **notas** e verifique com o método **db.notas.find().count()** quantos documentos foram inseridos:

```
for(i=0; i < 1000; i++) {
  atividades = ['prova', 'projeto', 'exercicios'];
  for (j=0; j < 3; j++) {
       db.notas.insert({'estudante' : i, 'tipo' : atividades[j],
                        nota : Math.round(Math.random() * 100)
       });
  }
}
```

a) Exiba os 10 primeiros documentos com o método limit() ao final do find()

7. Cadastre 6 documentos na coleção grade_curricular do banco de dados tads em mongoDB. Cada documento deve ter o semestre de oferta, como semestre_1, semestre_2 etc.. e as chaves codigo, componente, ch, pre_requisito, onde:

codigo: string do código do componente
compoente: string com a descrição (nome) do componente
ch: numero com as horas do componente
pre_requisito: array de strings com os pre-requisitos do componente (obs: escrever diretamente os nomes dos pre-requisitos)

Ao fim, terá uma coleção com a grade curricular do tads, podendo realizar crud nesta coleção.

7.1) elabore consulta que retorne a quantidade e o nome dos componentes que possuem algoritmos como pré-requisito

Quadro resumo comparação SQL x mongoDB:
OBS: ao usar pymongo ou outras libs, as chaves e parâmetros de busca podem ser delimitados por aspas simples, tal como em JS

As variantes findOne (find_one no pymongo) retorna apenas primeira ocorrência. find e findAll, assim como updateOne, updateMany, removeOne, removeMany
*alguns exemplos de referência: https://onecompiler.com/mongodb/3zpaqgcqb

SQL	**MongoDB**
`SELECT * FROM users`	`db.users.find()`
`SELECT * FROM users WHERE age = 33`	`db.users.find({age: 33})`
`SELECT * FROM users WHERE age > 33`	`db.users.find({age: {$gt: 33}})`

SELECT * FROM users WHERE age >= 33	db.users.find({age: {$gte: 33}})
SELECT * FROM users WHERE age < 33	db.users.find({age: {$lt: 33}})
SELECT * FROM users WHERE age <= 33	db.users.find({age: {$lte: 33}})
SELECT * FROM users WHERE age > 33 AND age < 40	db.users.find({age: {$gt: 33, $lt: 40}})
SELECT * FROM users WHERE age = 32 AND name = "Bob"	db.users.find({age: 32, name: "Bob"})
SELECT * FROM users WHERE age = 33 OR name = "Bob"	db.users.find({$or:[{age:33}, {name: "Bob"}]})
SELECT * FROM users WHERE age >= 32 AND (name = "Bob" OR job="Salesman")	db.users.find(age: {$gte:32}, $or: [{name: "Bob"}, {job: "Salesman"}] })
UPDATE Users SET age = 33 WHERE name = “Bob”	db.uses.update({name: “Bob”}, {$set : {age: 33}}, {multi:true}}
UPDATE Users SET age = 33+2 WHERE name = “Bob”	db.uses.update({name: “Bob”}, {$inc : {age: 2}}, {multi:true}}
DELETE FROM Users WHERE name = “Bob”	db.uses.remove({name: “Bob”}}
SELECT count(*) from megasena where Ganhadores_Sena" > 4	db.megasena.find({ "Ganhadores_Sena" : { $gt:4} }).count();
?	db.megasena.find({"Ganhadores_Sena":{$in:[5,6,7]}}).count( ) 4 // que possuem 5, 6 ou 7 ganhadores
select distinct("Ganhadores_Sena") from megasena	db.megasena.distinct("Ganhadores_Sena") // valores únicos, equivalente ao unique() do pandas

select nome
from megasena
	// nomes que tem a palavra ‘ad’
	db.seriados.find({ "nome": /ad/},{"nome":1,"_id":0})

where "nome" like '%ad%';	// resposta { "nome" : "Carga Pesada" } { "nome" : "Breaking Bad" }

	// para ficar case insensitive, usar /i
	db.seriados.find({ "nome": /bad/i},{"nome":1,"_id":0})

	// palavras que terminam usar $
	db.seriados.find({ "nome": /ad$/},{"nome":1,"_id":0})
	{ "nome" : "Breaking Bad" }

	// palavras que começam com padrão, usar ^
	db.seriados.find({ "nome": /^Ba/},{"nome":1,"_id":0})

	// ordenar resultado crescente (1) ou decrescente (-1) com método sort()
	db.seriados.find({},{_id:0,nome:1}).sort({ nome:1})

8. Marque CERTO ou ERRADO

( ) Os bancos relacionais permitem uma escalabilidade mais barata e menos trabalhosa que os bancos não relacionais, pois não exigem máquinas extremamente poderosas e sua facilidade de manutenção possibilita um número menor de profissionais necessários

( ) Considere-se que uma empresa de e-commerce deseja armazenar todos os dados relacionados às interações de clientes em seu site – registro de visitas, cliques, compras, avaliações, comentários, entre outros. Nessa situação, se a empresa decidir não estruturar e organizar esses dados antecipadamente, será melhor armazenar esses dados em uma solução *data lake* do que em um banco relacional

( ) O modelo em estrela e o modelo em floco de neve são os principais modelos de dados relacionais

( ) Um banco de dados que se encontra na 3FN obrigatoriamente está também na 2FN e na 1FN

( ) A integridade referencial é uma parte essencial de qualquer BD relacional, que, entre outros benefícios, facilita as consultas

( ) Hadoop é uma plataforma de código aberto que oferece uma solução tecnológica confiável e escalável para armazenamento e análise de grande quantidade de dados

( ) Spark é uma arquitetura de SO para trabalhar com dados organizados de forma hierárquica, utilizando-se o módulo Spark SQL, que permite consultar arquivos pelo seu conteúdo

( ) O PySpark funciona como uma interface entre Python e JAVA para a construção de pipelines de dados

( ) No que se refere aos Vs do big data, o termo volume refere-se a dados que, atualmente, não são estruturados nem armazenados em tabelas relacionais, o que torna sua análise mais complexa

( ) Ao serem armazenados no HDFS, os dados do Hadoop são divididos emblocos e distribuídos em discos distintos de um mesmo servidor, o que acelera o seu processamento, já que são pesquisados de forma simultânea, e não de forma sequencial

( ) Um projeto relacionado ao Hadoop e mantido pela Apache é o Hive, que é uma camada de data Warehouse que roda em cima do Hadoop e que utiliza uma linguagem similar à SQL, a Hive SQL

( ) Cypher query language é utilizada pelo Neo4j, que possibilita aos usuários o armazenamento e a recuperação de dados do BD baseado em grafos

( ) Uma coleção e um documento, no MongoDB, são equivalentes à tabela e à linha, no modelo relacional

( ) Os dados em streaming referem-se a dados que são gerados continuamente, geralmente em grandes volumes e em alta velocidade, por meio de diferentes fontes

( ) Processamento em lote envolve entrada, processo e saída contínua de dados, em que a chave é o tempo de resposta

( ) O Hadoop consiste num único produto, ou seja, é software monolítico, que possibilita análise de logs e outros dados da Web

( ) Uma das principais características de big data é que seu custo de armazenamento de dados é relativamente baixo se comparado a um data Warehouse

( ) Uma das características do data lake é armazenar um grande volume de dados brutos e heterogêneos, oriundos de diversas fontes distintas